



Entrega 2

Análisis y Segmentación Inteligente de turismo y hostelería en Chile.

<https://github.com/IICG-Coquimbo/proyecto-big-data-2026-equipo-de-turimos-y-hosteleria.git>

Integrantes: Martina Cortés

Camila Rojas

Bastian Bravo

Lucas Cheuque

Matias Gonzalez

Juan Salas

Angelo Rojo

Asignatura: Big data

Fecha: 05-06-2026



Resumen ejecutivo

Situación problema

Actualmente, los turistas que buscan alojamiento en Chile deben revisar múltiples plataformas para comparar precios y características de hospedaje. Esta situación dificulta encontrar la mejor alternativa, ya que los valores pueden variar significativamente entre plataformas para una misma ciudad o destino. Además, no existe una fuente centralizada que permita analizar estas diferencias considerando factores como la ubicación geográfica, la categoría del alojamiento o su evaluación por parte de los usuarios. Como consecuencia, tanto turistas como empresas del sector carecen de información estructurada que facilite la toma de decisiones basadas en datos reales del mercado.

Hallazgo Principal del Análisis de Datos

El análisis realizado sobre 3.146 alojamientos obtenidos tras un proceso de limpieza de 4.754 registros brutos recolectados desde siete plataformas digitales, permitió identificar diferencias significativas entre las zonas turísticas de Chile. Mediante segmentación con K-Means se detectaron cinco perfiles de alojamiento distintos, destacando un segmento Premium compuesto por 1.253 establecimientos con un precio promedio de \$143.506 CLP y una puntuación promedio de 8,67. Asimismo, se evidenció que los alojamientos mejor evaluados no siempre corresponden a los de mayor precio, lo que revela oportunidades concretas para turistas que buscan una mejor relación calidad-precio.

Tratamiento de Veracidad de los Datos

Para garantizar la calidad y confiabilidad de la información utilizada, se realizó un proceso estructurado de limpieza y validación. Se eliminaron registros con valores nulos o incompletos en variables relevantes para el estudio, así como duplicados que pudieran distorsionar los resultados. Los precios fueron estandarizados a formato numérico, removiendo símbolos monetarios y caracteres especiales que impedían su procesamiento.

Adicionalmente, se revisaron valores atípicos (*outliers*) en variables como precio por noche y puntuación, con el objetivo de detectar registros inconsistentes o errores de captura. Estas acciones permitieron obtener un conjunto de datos consistente, confiable y apto para las etapas de análisis y modelado.

En términos concretos: se partió de 4.754 registros brutos recolectados desde 7 plataformas digitales. Tras el proceso de limpieza eliminación de nulos y duplicados se obtuvieron 3.146 registros limpios, de los cuales 2.393 corresponden a alojamientos únicos verificados por nombre de establecimiento.

Ingeniería de atributos

Con el objetivo de enriquecer el análisis y obtener información más útil para la toma de decisiones, se generaron tres nuevas variables derivadas de los datos originales capturados por los scrapers:


- ❖ Relación calidad-precio: indicador calculado a partir de la puntuación del alojamiento y su precio por noche, permitiendo identificar opciones que ofrecen mejores prestaciones en relación con su costo.
- ❖ Segmento de precio: clasificación de los alojamientos en categorías (económico, medio o alto), facilitando el análisis comparativo entre distintos perfiles de hospedaje.

- ❖ Evaluación de conveniencia: variable binaria que determina si un alojamiento representa una alternativa conveniente para el turista, considerando conjuntamente su precio y su valoración general.

Análisis descriptivo (EDA)

Gráfico 1 de Boxplot: Competencia Regional por Plataforma

Variables: Precio por Noche (CLP) × Zona Geográfica × Plataforma




Este gráfico muestra la distribución de precios por noche en las 8 zonas geográficas de Chile, diferenciando cada plataforma con color. Se pueden extraer tres conclusiones relevantes:

- ❖ HotelsCombined.com y Booking.com presentan consistentemente las medianas más altas en casi todas las zonas, especialmente en Norte Chico y Centro, donde alcanzan rangos de CLP 300.000 -- 470.000. Esto sugiere que estas plataformas concentran alojamientos del segmento premium.
- ❖ La zona Centro muestra la mayor dispersión de precios (bigotes muy amplios), lo que indica un mercado heterogéneo con oferta tanto económica como de lujo. Esto es relevante para estrategias de segmentación.
- ❖ Kayak.cl, Expedia.cl y Google Hotels mantienen precios consistentemente bajos y con poca varianza en casi todas las regiones, posicionándose como plataformas del segmento económico-masivo.
- ❖ La zona Norte tiene los rangos más comprimidos y bajos del país, lo que podría reflejar menor desarrollo turístico o menor competencia entre plataformas.

Gráfico 2 — Matriz Estratégica: Precio vs Puntuación (por alojamiento individual)

Variables: Precio por Noche (CLP) × Puntuación del Hotel × Plataforma




Este scatter plot posiciona cada alojamiento en una matriz de cuatro cuadrantes definidos por el precio promedio (CLP 131.872) y la nota promedio (7.4). Permite identificar segmentos estratégicos

El hallazgo más relevante es que la mayoría de los alojamientos se concentran bajo los CLP 200.000, independiente de la plataforma, con una cola de precios extremos que corresponde casi exclusivamente a Booking.com.

Gráfico 3 — Mapa de Posicionamiento: Precio Promedio vs Calidad Promedio por Plataforma

Variables: Precio Promedio por Noche (CLP) × Puntuación Promedio × Plataforma (tamaño de burbuja = volumen de oferta)





Este gráfico agrega los datos por plataforma, permitiendo una comparación directa de su posicionamiento estratégico:

- ❖ Booking.com lidera en calidad promedio (8.3) con un precio moderado (CLP 185.000), consolidándose como la plataforma con mejor relación precio-calidad a nivel agregado.
- ❖ NotelsCombined.com alcanza alta calidad (7.8) pero al precio más alto del grupo (CLP 275.000), orientándose a un público dispuesto a pagar más.
- ❖ Expedia.cl, Despegar.cl y Trip.com se agrupan en el cuadrante de alta calidad / precio bajo (CLP 85.000 -- 100.000), siendo opciones eficientes para el viajero informado.
- ❖ Airbnb.cl y airbnb.cl (dos instancias distintas scrapeadas) presentan puntuaciones muy bajas (~3.5) con precios relativamente altos (CLP 240.000 -- 330.000), lo que las ubica en el cuadrante de menor valor percibido. Esto puede deberse a que el sistema de puntuación difiere entre plataformas hoteleras y de alquiler por habitación.
- ❖ Google Hotels aparece con puntuación cercana a 0, lo que sugiere que esta plataforma no entrega datos de rating directamente en el scraping, siendo un dato a considerar para el modelado predictivo.

Síntesis EDA que da respuesta a la Pregunta de Negocio:

¿Qué plataforma ofrece el mejor valor para alojarse en Chile según zona geográfica?

El análisis multivariado revela que no existe una plataforma universalmente superior: la elección óptima depende de la zona y el segmento buscado. Booking.com domina en calidad general, pero plataformas como Despegar.cl y Expedia.cl ofrecen buena calidad a menor costo. La zona Centro concentra la mayor competencia y variedad de precios, mientras que zonas como Norte y Sur presentan mercados más homogéneos y económicos. Estos hallazgos justifican la segmentación por clustering en la siguiente sección.

Técnica Utilizada:

Para la segmentación de alojamientos se utilizó el algoritmo K-Means. El número óptimo de clústeres se determinó mediante el Método del Codo, evaluando distintos valores de k entre 2 y 10. Tras analizar la curva obtenida se seleccionó k = 5, ya que representaba un punto de equilibrio entre simplicidad y capacidad de diferenciación de grupos.

Perfilamiento de clústeres

prediction	cantidad	precio_promedio	puntuacion_promedio	estrellas_promedio
0	1253	143505.64485235434	8.686831613207282	0.3383878691141261
1	494	57701.86842105263	3.678421054291822	0.29959514170040485
2	1120	115696.18303571429	8.194821430955614	3.3660714285714284
3	917	294358.27153762267	5.521648850409779	4.591057797164668
4	624	95862.53205128205	2.1796474357446036	0.06891025641025642



Con esto podemos concluir que:

Clúster 0 de Alojamientos Premium:

Este grupo concentra 1.253 alojamientos y presenta el precio promedio más elevado (\$143.506). Además, posee una puntuación promedio de 8,67, indicando un alto nivel de satisfacción de los usuarios. Corresponde principalmente a alojamientos de categoría superior orientados a turistas que buscan mayor calidad y comodidad.

Clúster 1 de Alojamientos Económicos de Baja Valoración

Con 494 registros, este clúster presenta el precio promedio más bajo (\$57.702). También registra una puntuación promedio relativamente baja (3,68). Representa alojamientos económicos, generalmente seleccionados por viajeros con presupuesto limitado.

Clúster 2 de Alojamientos de Calidad Intermedia

Este grupo reúne 1.120 alojamientos con un precio promedio de \$115.696 y una puntuación promedio de 8,19. Corresponde a establecimientos que ofrecen una buena relación entre precio y calidad, siendo una alternativa atractiva para turistas que buscan equilibrio entre costo y servicio.

Clúster 3 de Alojamientos de Alta Categoría y Reputación

Con 917 alojamientos, este segmento presenta una puntuación promedio de 5,52 y el promedio de estrellas más alto (4,59). Aunque su precio promedio (\$29.436) es inferior al de otros grupos, destaca por incluir establecimientos con mejores características de clasificación hotelera y reconocimiento dentro de la plataforma.

Clúster 4 de Alojamientos Básicos

Este grupo está compuesto por 624 alojamientos con un precio promedio de \$95.862 y una puntuación promedio de 2,18. Corresponde principalmente a alojamientos de categoría básica que ofrecen servicios limitados y reciben valoraciones inferiores respecto de otros segmentos.

Se definieron 5 clusters ($k=5$), obteniendo grupos diferenciados de alojamientos. La segmentación generó los clusters 0, 1, 2, 3 y 4, con tamaños de 1253, 494, 1120, 917 y 624 registros respectivamente.

Recomendaciones Estratégicas

A partir de los resultados obtenidos mediante la segmentación de alojamientos, se identificaron oportunidades que pueden contribuir a una mejor toma de decisiones dentro del sector turístico y hotelero:

Promocionar los alojamientos del Clúster 2 como alternativas de buena relación calidad-precio para turistas que buscan equilibrar costo y calidad.

Potenciar campañas de marketing dirigidas a turistas nacionales e internacionales para los alojamientos Premium identificados en el Clúster 0.

Implementar estrategias de mejora en los alojamientos pertenecientes a los Clústeres 1 y 4, con el objetivo de aumentar la satisfacción de los usuarios y mejorar sus evaluaciones.

Utilizar la segmentación obtenida para personalizar ofertas, promociones y servicios según el perfil de cada grupo de clientes.

Apoyar la planificación turística regional mediante la identificación de zonas con mayor concentración de alojamientos de alta calidad.



Definición Predictiva y Meta-Datos

Variable a Predecir (Y)

- ❖ Para la última entrega del proyecto (Hito 3), definimos que nuestra variable objetivo a predecir será `"precio_noche_clp"`, correspondiente al precio por noche del alojamiento expresado en pesos chilenos.
- ❖ El objetivo es que el modelo aprenda a calcular automáticamente la tarifa óptima según las condiciones del mercado, permitiendo automatizar estrategias de tarificación dinámica en el sector turismo y hotelería en Chile.

Factibilidad del Modelo Supervisado

El conjunto de datos actual cumple con todas las condiciones necesarias para entrenar un modelo de Machine Learning supervisado con éxito, por tres razones fundamentales:

Volumen de datos suficiente:

Contamos con 3.146 registros limpios almacenados en MongoDB Atlas. Esta cantidad supera con creces el mínimo necesario para dividir los datos en un grupo de entrenamiento (80%) y otro de prueba (20%), cumpliendo además con el requisito del proyecto de al menos 500 registros por integrante. Un volumen de esta magnitud permite que el modelo generalice correctamente sin caer en sobreajuste

Variables explicativas útiles (X)

El modelo utilizará las siguientes variables predictoras que influyen directamente en el precio:

Tipo de Variable	Variables
Originales	Puntuación de usuarios, cantidad de estrellas del hotel, zona geográfica, tipo de alojamiento
Derivadas (Ingeniería de atributos)	Relación calidad-precio, segmento de precio, conveniencia

Estas variables aportan información valiosa y diversa para que el modelo aprenda patrones significativos del mercado.

Datos representativos del mercado real:

La información fue recolectada desde **7 plataformas distintas**, lideradas por Booking y Kayak. Esto garantiza que el modelo no presente sesgos provenientes de una única fuente y pueda aprender cómo funciona el mercado real del alojamiento en Chile, considerando diferentes canales de oferta y demanda.



Algoritmos Propuestos para el Hito 3:

Para la predicción de la variable "precio_noche_clp", se propone evaluar los siguientes algoritmos de aprendizaje supervisado.

Algoritmo	Justificación
Regresión Lineal	Modelo base para establecer una referencia de rendimiento y medir la linealidad de las relaciones
Random Forest Regressor	Captura relaciones no lineales, maneja interacciones entre variables y es robusto frente a outliers
XGBoost Regressor	Optimiza la precisión predictiva, maneja overfitting mediante regularización y es eficiente con volúmenes medios de datos

Métricas de Evaluación:

La evaluación del mejor modelo se realizará mediante las siguientes métricas:

1. RMSE (Root Mean Square Error):* Para medir el error promedio en pesos chilenos de las predicciones.
2. R^2 (Coeficiente de Determinación):* Para evaluar qué porcentaje de la variabilidad del precio es explicado por el modelo.

Estudiante	Responsabilidad Técnica Específica	Rama de Trabajo	N°
Martina Cortés	Análisis Descriptivo (EDA): gráficos, correlaciones, boxplots y informe	martina-cortes	8
Camila Rojas	Modelado No Supervisado: K-Means, Método del Codo, interpretación de clústeres	Camila-rojas	13
Bastian Bravo	Scraping y Captura de Datos: extracción web, actualización de precios y Informe	bastian-bravo10	7
Lucas Cheuque	Ingeniería de Datos y Pipeline: contenedor de limpieza y carga a processed_data	Lucas-Cheuque	8
Juan pablo Salas	Scraping y Captura de Datos: extracción web, actualización de precios	Juan-Salas	7



Angelo Rojo	Scraping y Captura de Datos: extracción web, actualización de precios	Angelo-Rojo	7
Matias Gonzalez	Documentación y Calidad: informe PDF, repositorio, estándares de commit	matias-gonzalez	7

Resumen de Hallazgos y Proyección

Hallazgos Principales del Análisis:

El presente estudio permitió caracterizar el mercado de alojamiento turístico en Chile a partir de un conjunto de *3.146 registros limpios*, recolectados desde 7 plataformas digitales distintas, lideradas por Booking y Kayak. A continuación, se resumen los principales hallazgos obtenidos:

Relación entre precio y puntuación:

El gráfico de dispersión reveló que los alojamientos con mejores evaluaciones no necesariamente presentan los precios más altos. Esta situación evidencia la existencia de alternativas con buena valoración por parte de los usuarios y costos moderados, lo que resulta especialmente atractivo para turistas que buscan maximizar su relación calidad-precio. Asimismo, se identificaron alojamientos con precios elevados pero puntuaciones similares a opciones más económicas, lo que sugiere diferencias significativas en la percepción de valor ofrecida por cada establecimiento.

Factores que influyen en el precio:

El mapa de correlación permitió identificar una relación positiva entre el precio por noche y la cantidad de estrellas del alojamiento, confirmando que los establecimientos de mayor categoría hotelera tienden a tener precios más elevados. También se detectó una correlación moderada entre la puntuación de los usuarios y la variable creada "relación calidad-precio", lo que indica que los alojamientos mejor evaluados suelen ofrecer una experiencia más satisfactoria en términos de valor recibido por el costo pagado.

Variabilidad de precios por tipo de alojamiento:

El análisis mediante boxplots mostró que los hoteles presentan una mayor variabilidad de precios en comparación con hostales y departamentos, que mantienen rangos más acotados. Además, se observó la presencia de valores extremos en algunas categorías, reflejando la existencia de alojamientos premium orientados a segmentos específicos del mercado con mayor capacidad de gasto.



Segmentación de la oferta turística

Mediante la aplicación del algoritmo *K-Means* con $k=5$ (determinado a través del Método del Codo), se logró segmentar la oferta turística en cinco clusters diferenciados:

- ❖ Clúster 0 – Alojamientos Premium:* 1.253 registros, precio promedio de \$146.506 y puntuación promedio de 8,67. Corresponde a alojamientos de categoría superior.
- ❖ Clúster 1 – Alojamientos Económicos de Baja Valoración:* 494 registros, precio promedio de \$57.702 y puntuación promedio de 3,68. Orientado a viajeros con presupuesto limitado.
- ❖ Clúster 2 – Alojamientos de Calidad Intermedia:* 1.120 registros, precio promedio de \$115.696 y puntuación promedio de 8,19. Alternativa equilibrada entre costo y servicio.
- ❖ Clúster 3 – Alojamientos de Alta Categoría y Reputación:* 917 registros, puntuación promedio de 5,52 y promedio de estrellas más alto (4,59). Destaca por su reconocimiento institucional.
- ❖ Clúster 4 – Alojamientos Básicos:* 624 registros, precio promedio de \$95.862 y puntuación promedio de 2,18. Servicios limitados y valoraciones inferiores.

Esta segmentación permite a las empresas del sector turístico comprender mejor su posicionamiento relativo en el mercado y diseñar estrategias de tarificación diferenciadas según el perfil de cada segmento.

Proyección para el Hito 3

Para la próxima entrega del proyecto (Hito 3), se ha definido como variable objetivo a predecir `"precio_noche_clp"` (precio por noche en pesos chilenos). El objetivo es que el modelo de Machine Learning aprenda a calcular automáticamente la tarifa óptima según las condiciones del mercado, permitiendo automatizar estrategias de tarificación dinámica en el sector turismo y hotelería.

Se propone evaluar los siguientes algoritmos de aprendizaje supervisado:

- ❖ Regresión Lineal:* Como modelo base para establecer una referencia de rendimiento inicial.
- ❖ Random Forest Regressor:* Para capturar relaciones no lineales, manejar interacciones entre variables y ser robusto frente a outliers.
- ❖ XGBoost Regressor:* Con el fin de optimizar la precisión predictiva, manejar el sobreajuste mediante regularización y ser eficiente con volúmenes medios de datos.

La evaluación del mejor modelo se realizará mediante dos métricas clave: *RMSE (Root Mean Square Error)* para medir el error promedio en pesos chilenos de las predicciones, y *R² (Coeficiente de Determinación)* para evaluar qué porcentaje de la variabilidad del precio es explicado por el modelo.

Finalmente, se confirma que el conjunto de datos actual cumple con todas las condiciones necesarias para el entrenamiento supervisado: volumen suficiente (3.146 registros), variables predictoras relevantes (originales y derivadas) y representatividad del mercado real chileno gracias a la recolección desde múltiples plataformas